

REDES NEURONALES Y APRENDIZAJE PROFUNDO

Predicción de Consumo Eléctrico en España mediante una red LSTM

Universidad Alfonso X el Sabio (UAX)

1. Introducción y objetivo del proyecto

Este trabajo aborda el problema de predicción del consumo eléctrico real en España mediante técnicas de aprendizaje profundo, concretamente redes neuronales recurrentes del tipo Long Short-Term Memory (LSTM).

La predicción de la demanda eléctrica es uno de los problemas más relevantes en el sector energético. Una estimación precisa permite a los operadores del sistema equilibrar la generación y el consumo, reducir costes y facilitar la integración de energías renovables. En España, esta función la realiza Red Eléctrica de España (REE), el Transmission System Operator (TSO), que publica sus propias previsiones horarias.

El objetivo de este proyecto es construir un modelo LSTM capaz de predecir el consumo eléctrico de la hora siguiente dado un historial de 24 horas, y comparar su rendimiento contra la previsión oficial del TSO como baseline de referencia.

1.1 Dataset

Se ha utilizado el dataset público disponible en Kaggle:

"Hourly energy demand generation and weather"

El dataset contiene datos horarios para España durante el periodo 2015-2018, con dos ficheros principales:

- `energy_dataset.csv`: 35.064 registros con generación por fuente (nuclear, eólica, solar, gas, hidro...), consumo real, previsión del TSO y precio del mercado.
- `weather_features.csv`: 178.396 registros con datos meteorológicos (temperatura, humedad, viento, nubosidad) para las 5 ciudades más grandes de España (Madrid, Barcelona, Valencia, Sevilla, Bilbao).

Ambos ficheros comparten el mismo rango temporal y pueden unirse mediante la columna de timestamp.

2. Análisis Exploratorio de Datos (EDA)

2.1 Análisis básico

El dataset de energía no contiene duplicados. Se identificaron dos columnas con el 100% de valores nulos (generation hydro pumped storage aggregated y forecast wind offshore eday ahead) que fueron eliminadas. El resto de columnas presentan menos de un 0.1% de nulos, tratados mediante interpolación lineal.

La variable objetivo total load actual presenta 36 valores nulos que fueron eliminados directamente al ser filas sin etiqueta válida.

Métrica	Valor	Descripción
Registros	35.028	Tras limpieza
Periodo	2015-2018	4 años completos
Consumo medio	~28.700 MW	total load actual
Consumo mínimo	~17.000 MW	Madrugadas agosto
Consumo máximo	~41.000 MW	Invierno hora punta

2.2 Análisis estadístico y patrones temporales

El consumo eléctrico presenta una estructura temporal muy clara con tres niveles de estacionalidad:

- Estacionalidad horaria: dos picos diarios, uno a las 10-11h y otro a las 20-21h, separados por un valle nocturno (3-6h) y una caída relativa a las 14-15h (hora de la siesta).
- Estacionalidad semanal: el consumo en días laborables es significativamente mayor que en fin de semana, con diferencias de hasta 4.000 MW en hora punta.
- Estacionalidad anual: mayor consumo en invierno y verano por el efecto de calefacción y climatización, con un mínimo en primavera y otoño.

La distribución del consumo muestra una forma bimodal, reflejo de los dos modos del sistema: consumo bajo (noches y fines de semana) y consumo alto (días laborables).

2.3 Correlaciones y relación con el clima

La matriz de correlación revela que la previsión del TSO (total load forecast) tiene una correlación de 0.97 con el consumo real, lo que la convierte en el mejor predictor individual disponible. Sin embargo, y de forma deliberada, esta variable fue excluida de las features del modelo LSTM para evitar que este dependiese de la información privilegiada del TSO y para hacer el ejercicio más honesto desde un punto de vista predictivo.

La temperatura muestra una relación en forma de U con el consumo: tanto el frío extremo como el calor extremo incrementan la demanda, por el uso de calefacción y aire acondicionado respectivamente.

2.4 Baseline del TSO

Se calculo el MAE de la previsión del TSO sobre el conjunto de test como referencia:

Modelo	MAE (MW)
Previsión TSO (baseline)	~254 MW
LSTM (nuestro modelo)	~370 MW

El TSO utiliza modelos propietarios con datos meteorológicos de alta resolución, calendarios laborales, eventos especiales y décadas de datos históricos, lo que explica su mayor precisión.

3. Modelo y métricas

3.1 Preprocesamiento

Se realizaron los siguientes pasos de preprocesamiento previos al entrenamiento:

- Merge de los datasets de energía y clima mediante el timestamp común, agregando el clima como media horaria de las 5 ciudades.
- Extracción de features temporales cíclicas (seno/coseno de hora, día de la semana y mes) para que la LSTM entienda la continuidad temporal (e.g. que la hora 23 y la hora 0 son consecutivas).
- Normalización con MinMaxScaler al rango $[0,1]$. El scaler se ajustó exclusivamente con los datos de entrenamiento para evitar data leakage.
- Construcción de ventanas deslizantes de 24 timesteps: cada muestra consiste en 24 horas de historial para predecir el consumo de la hora siguiente.

3.2 División train/val/test

El split se realizó de forma temporal (sin mezcla aleatoria) para respetar la estructura cronológica de los datos:

Conjunto	Porcentaje	Periodo aprox.
Train	70%	2015 – mid 2017
Validación	15%	mid 2017 – mid 2018
Test	15%	mid 2018 – fin 2018

Se uso TimeSeriesSplit conceptualmente: los datos futuros nunca son vistos durante el entrenamiento.

3.3 Arquitectura LSTM

Se diseñó una arquitectura de dos capas LSTM apiladas con regularización mediante Dropout:

Capa	Tipo	Detalle
1	LSTM	128 unidades, return_sequences=True
2	Dropout	0.2 (20%)
3	LSTM	64 unidades, return_sequences=False
4	Dropout	0.2 (20%)
5	Dense	32 unidades, activacion ReLU
6	Dense	1 unidad (salida, regresion)

La primera capa LSTM (128 unidades) aprende patrones temporales complejos sobre la secuencia de 24 horas. Al usar return_sequences=True, devuelve la salida en cada

timestep para que la segunda capa pueda procesar la secuencia completa. La segunda capa LSTM (64 unidades) refina las representaciones aprendidas y produce un único vector de estado final. Las capas Dense realizan la transformación final hacia el valor de consumo predicho.

El Dropout actúa exclusivamente durante el entrenamiento, desactivando aleatoriamente el 20% de las neuronas en cada forward pass para prevenir el overfitting.

Parámetros de entrenamiento:

- Optimizador: Adam (learning rate = 0.001)
- Función de pérdida: MSE (Error Cuadrático Medio)
- Métrica de monitoreo: MAE
- EarlyStopping: patience=10 épocas sobre val_loss
- ModelCheckpoint: guarda el mejor modelo según val_loss
- Épocas máximas: 50 | Batch size: 64

3.4 Por que LSTM y no RNN simple

Las redes recurrentes simples (RNN) sufren el problema del vanishing gradient: al propagar el gradiente hacia atrás en el tiempo mediante multiplicaciones encadenadas de la matriz de pesos, este se vuelve exponencialmente pequeño con secuencias largas, impidiendo que las capas iniciales aprendan.

Las LSTM resuelven este problema mediante tres puertas aprendibles:

- Puerta de olvido (forget gate): decide que información del estado anterior descartar. Produce valores entre 0 y 1 que se multiplican elemento a elemento por el estado de celda.
- Puerta de entrada (input gate): decide que información nueva añadir al estado de celda, trabajando junto a una función tanh que genera los candidatos.
- Puerta de salida (output gate): decide que parte del estado de celda se expone como estado oculto al siguiente timestep.

El gradiente fluye a través del estado de celda mediante operaciones aditivas, no multiplicativas, lo que permite que llegue intacto a timesteps lejanos. Con una ventana de 24 horas, esto es crítico para que el modelo recuerde patrones del inicio del día cuando predice al final.

3.5 Hyperparameter Tuning

Se realizó una búsqueda sistemática de hiperparámetros mediante RandomSearch de Keras Tuner, explorando 15 combinaciones aleatorias sobre el siguiente espacio de búsqueda:

Hiperparametro	Valores explorados
Unidades LSTM capa 1	64, 128, 256
Unidades LSTM capa 2	32, 64, 128
Dropout	0.1, 0.2, 0.3

Learning rate	0.001, 0.0005, 0.0001
---------------	-----------------------

Cada trial se entrenó con un máximo de 20 épocas y EarlyStopping (patience=5). El mejor modelo encontrado se entrenó posteriormente hasta convergencia completa con patience=10.

3.6 Métricas de evaluación

Al tratarse de un problema de regresión, se utilizaron las siguientes métricas en lugar de las típicas de clasificación (accuracy, precision, recall, F1):

- MAE (Mean Absolute Error): error absoluto medio en MW. Es la métrica más interpretable: indica cuantos MW se equivoca el modelo en media.
- RMSE (Root Mean Squared Error): penaliza más los errores grandes que el MAE. Útil para detectar si el modelo comete errores puntuales severos.
- R2 (coeficiente de determinación): mide que proporción de la varianza del consumo es explicada por el modelo. Un valor de 1.0 sería predicción perfecta.

La matriz de confusión no aplica en regresión. En su lugar, se incluye el scatter plot real vs predicho y la distribución del error, que cumplen una función análoga: permiten visualizar si el modelo tiene sesgos sistemáticos.

Modelo	MAE (MW)	R2
LSTM original	~370 MW	~0.93
LSTM tuneado	~300 MW	~0.99
TSO (baseline)	~254 MW	—

El error del modelo LSTM representa aproximadamente un 1.5% sobre el consumo medio de 28.700 MW, resultado competitivo dado que no se dispone de los datos privilegiados que utiliza el TSO (previsiones meteorológicas profesionales, calendarios laborales, eventos especiales).

4. Aplicación Streamlit

Se desarrollo una aplicación interactiva con Streamlit que permite predecir el consumo eléctrico para cualquier hora del periodo 2015-2018.

Flujo de la aplicación:

- El usuario selecciona una fecha mediante un date picker y una hora mediante un slider.
- La app carga automáticamente las 24 horas anteriores del dataset real como contexto.
- El modelo LSTM genera la predicción del consumo para esa hora.
- Se muestran tres métricas: predicción LSTM, valor real y error absoluto.
- Se visualiza la serie temporal de las 24 horas de contexto con la predicción superpuesta.
- Se muestra la comparativa con la previsión del TSO para esa misma hora.

La app se ejecuta con el comando: `streamlit run app.py`

5. Conclusiones

5.1 Resultados

El modelo LSTM entrenado consigue un MAE de aproximadamente 415 MW sobre el conjunto de test, frente a los 254 MW de la previsión oficial del TSO. Aunque no supera al baseline, el resultado es satisfactorio considerando las diferencias en los datos disponibles.

Las curvas de pérdida muestran una convergencia limpia sin overfitting, con `val_loss` consistentemente inferior a `train_loss` durante el entrenamiento. Esto se atribuye al efecto del Dropout, que actúa solo durante el entrenamiento.

El modelo muestra un comportamiento heterogéneo según la franja horaria: predice con mayor precisión durante las horas de la madrugada y la mañana, y comete errores mayores en la franja 20-23h, donde la caída del consumo tras el pico nocturno es más variable y difícil de anticipar.

5.2 Limitaciones

- El dataset cubre solo 4 años (2015-2018), lo que limita la capacidad del modelo para aprender patrones interanuales.
- Los datos meteorológicos son medias de 5 ciudades, perdiendo resolución espacial frente a los datos que usa el TSO.
- No se dispone de calendarios laborales ni información sobre eventos especiales que afectan al consumo.
- La ventana de 24 horas puede ser insuficiente para capturar dependencias a más largo plazo (semana completa).

5.3 Líneas de mejora

- Ampliar la ventana temporal a 48 o 168 horas (una semana) para capturar patrones semanales completos.
- Incorporar variables de calendario (festivos, puentes) como features binarias.
- Explorar arquitecturas Transformer o modelos híbridos CNN-LSTM para capturar patrones locales y globales simultáneamente.
- Ampliar el hyperparameter tuning con un mayor número de trials y espacio de búsqueda más amplio.
- Usar datos de generación renovable en tiempo real para mejorar la precisión en horas con alta variabilidad eólica o solar.